# 法律声明

□ 本课件包括:演示文稿,示例,代码,题库,视频和声音等,小象学院拥有完全知识产权的权利;只限于善意学习者在本课程使用,不得在课程范围外向任何第三方散播。任何其他人或机构不得盗版、复制、仿造其中的创意,我们将保留一切通过法律手段追究违反者的权利。



关注 小象学院



### 第十课 C语言工程与学习建议

林沐



### 内容概述

1.工程背景概述:搜索引擎

2.工程背景概述: 网页收录与计算

3.工程背景概述: 网页与HTML解析

4.C语言工程:开源库gumbo解析网页

5.gumbo编译

6.使用htmlparser获取网页标题

7.整体程序

8.gumbo数据结构使用与算法

9.标题文本提取

10.编译与测试

11.一些建议:关于学习

12.一些建议:关于算法之路

13.一些建议:关于算法之路

14.一些建议:关于面试

15.一些建议:关于实习

16.一些建议:关于求职谈薪资

17.一些建议:关于职场

18.一些建议:大小公司的比较

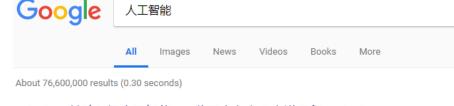
19.一些建议:关于人工智能



### 工程背景概述: 搜索引擎

#### 一个搜索事件:





Udacity 0基础入门人工智能 | 硅谷无人车之父主讲课程 | udacity.com [Ad] udacity.com/▼

Udacity与滴滴\BAT等科技名企合作,系统性学习Python编程,数学与统计基础,立即试听机器学习入门·深度学习·机器学习进阶

#### 人工智能-维基百科,自由的百科全书

https://zh.wikipedia.org/zh-hans/人工智能 ▼ Translate this page

人工智能(英语:Artificial Intelligence, AI)亦稱機器智能,是指由人製造出來的機器所表現出來的智能。通常人工智能是指通過普通電腦程式的手段實現的類人智能技術。該詞同時也指研究這樣的智能系統是否能夠實現,以及如何實現的科學領域。一般教材中的定义领域是"智能主体(intelligent agent)的研究与设计",智能主体是指一个…

人工智能(电影)·機器人學·机器视觉

无论<mark>搜索引擎</mark>如何升级与迭代,无论用<mark>何种手段</mark>,搜索引擎就是在做<mark>三件事</mark>:

理解用户行为:语音、文字、图片等等输入

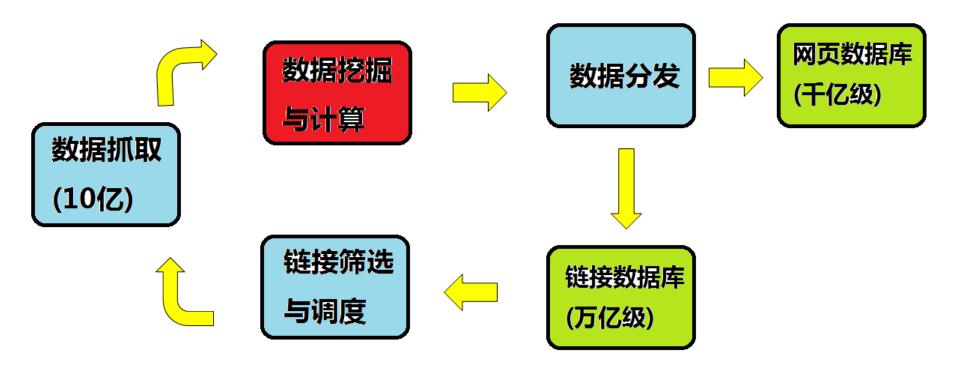
收录并理解互联网数据:网页

将用户行为与互联网数据建立联系,并推荐结果



### 工程背景概述: 网页收录与计算

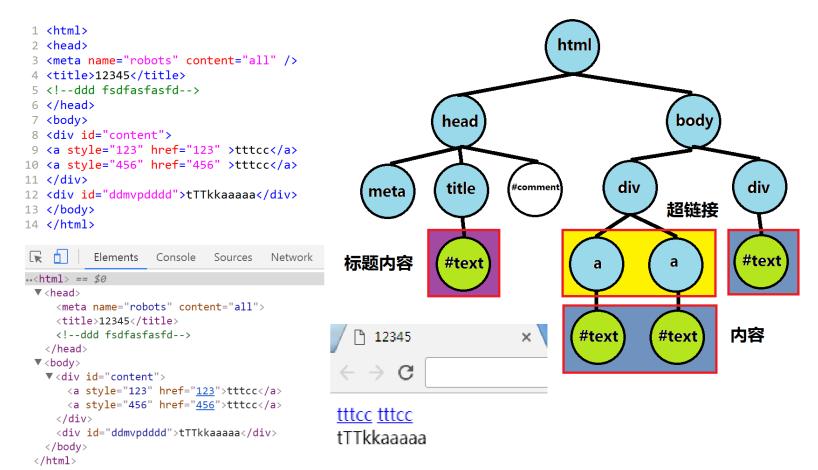
搜索引擎最基础的系统:**spider数据收录与数据挖掘**系统,一个**全网搜引擎**(google、baidu、sogou)的**spider系统**每日至少**调度抓取**十亿级链接,整个spider数据库会收录存储 **千亿级网页与万亿级链接**,它是一个环状系统。



### 工程背景概述: 网页与HTML解析

spider最为基础的环节就是<mark>网页(HTML)解析,网页解析</mark>即将网页源码HTML字符串转为计算机可以理解的数据结构,HTML树,即dom树。

如下图,蓝色的是标签节点(Element),绿色的是文本节点(Text)。标签节点标识了HTML文档的逻辑结构, 文本节点是HTML文档的内容,内容可以显示在浏览器中。在HTML文档中,有很多重要的内容用于分析网页属 性,例如HTML文档标题,HTML文档中的超链接,HTML文档中的文本内容。



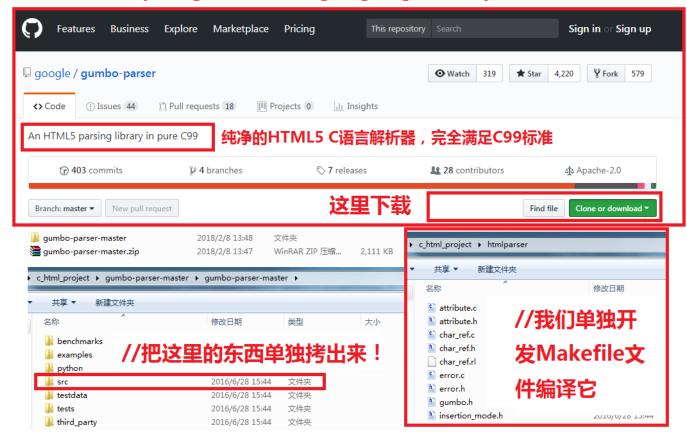
op.cn

# C语言工程: 开源库gumbo解析网页

gumbo是**Google的研发团队**开发的开源的**C语言HTML解析器**,它完全符合**C99标准**(我们的课程是基于**C89** 讲解的),它完全**不依赖**其他任何第三方库,且支持**最新HTML5标准**,经过了**Google搜索引擎**索引的25亿的网页测试,是不可多得的**HTML解析器**!

源码下载地址:https://github.com/google/gumbo-parser,完成下载后,将src中的源码单独拷贝到另外的文件夹,我们单独开发Makefile文件编译它(不使用Google自带编译脚本)。

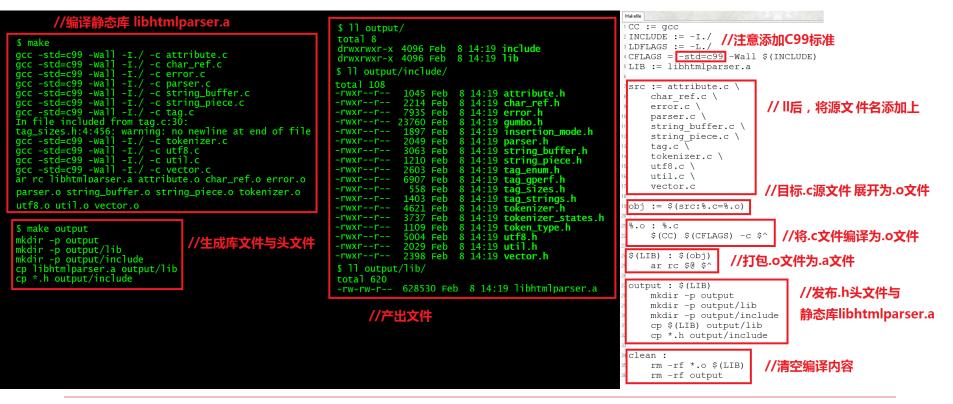
#### https://github.com/google/gumbo-parser





# gumbo编译

在htmlparser目录(保存src文件夹的所有内容)下,单独开发Makefile文件编译 gumbo,生成htmlparser解析器。发布内容output包括两部分,头文件output/include目录,与静态链接库output/lib目录,将全部.h文件拷贝至output/include目录,将静态库 libhtmlparser.a拷贝至output/lib。





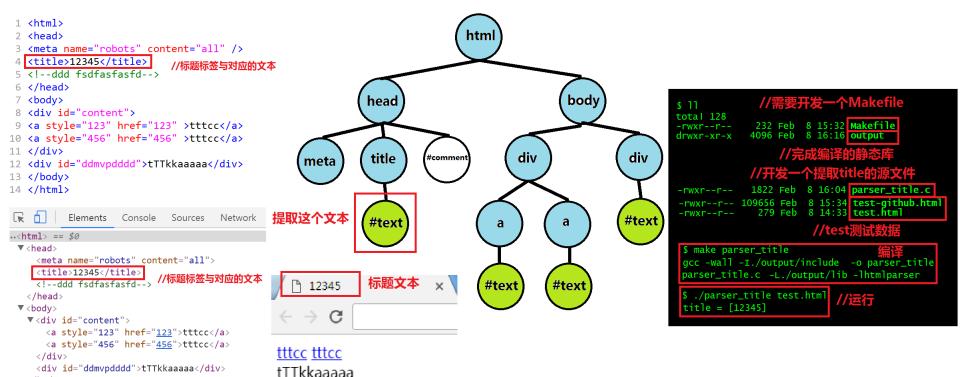
# 使用htmlparser获取网页标题

完成gumbo代码编译后,使用发布的output/lib静态库libhtmlparser.a与对应的头文件output/include,开发一个提取网页标题的程序parser\_title.c。已知标题标签是<title>,它一定是<head>标签的孩子,<head>标签一定是<html>标签的孩子。

#### 思考:

</body>

- 1.如何将<mark>网页读入,并输入给gumbo的解析接口</mark>?
- 2.如何获取title标签?又如何获取title标签中的文本?
- 3.完成代码开发后,如利用Makefile<mark>编译该</mark>工具?



```
#include <stdio.h>
#include <string.h>
#include "gumbo.h" //包含gumbo头文件
```

# 整体程序,课堂练习

```
void parser title(const GumboOutput *output, char title[]){
     //传入gumbo解析结果,传出title,存储在字符数组title中
char g_page[2 * 1024 * 1024] = {0}; //存储网页与网页长度的全局变量
int g page len = 0;
int read page(const char *file name) {
   FILE *fp = fopen(file name,
   if (!fp) {
                     //将文件file_name的内容读取并存储至g_page
       return -1;
                     中,g_page_len代表g_page中的有效字符数
   int ch;
                     //文件打开失败返回-1,成功返回0
   ch = fgetc(fp);
   while (
       ch = fgetc(fp);
   return 0;
int main(int argc, char *argv[]){
    if
       printf("usage : ./parser title html\n");
       return -1;
   if (read page(argv[1]) != 0) {
       printf("cannot open file %s.\n", argv[1]);
       return -1;
                       //调用gumbo解析器
   GumboOutput* output = gumbo parse with options(
           &kGumboDefaultOptions, g page, g page len);
    char title [10240] = \{0\};
    parser title (output, title);
   printf("title = [%s]\n", title); //打印解析出的title
    return 0;
```

3分钟,填写代码,有问题提出!



```
#include <stdio.h>
#include <string.h>
#include "gumbo.h"
                   //包含gumbo头文件
void parser title(const GumboOutput *output, char title[]) {
     //传入gumbo解析结果,传出title,存储在字符数组title中
char g page[2 * 1024 * 1024] = {0}; //存储网页与网页长度的全局变量
int g page len = 0;
int read page(const char *file name) {
   FILE *fp = fopen(file name,
   if (!fp) {
                     //将文件file_name的内容读取并存储至g_page
       return -1;
                     中,g_page_len代表g_page中的有效字符数
   int ch;
                     //文件打开失败返回-1 , 成功返回0
   ch = fqetc(fp);
           ch!= EOF
   while (
         g_page[g_page_len++] = ch;
       ch = fgetc(fp);
       fclose(fp);
    return 0;
int main(int argc, char *argv[]){
    if
          argc != 2
       printf("usage : ./parser title html\n");
        return -1;
    if (read page(argv[1]) != 0) {
       printf("cannot open file %s.\n", argv[1]);
        return -1;
                       //调用gumbo解析器
    GumboOutput* output = gumbo parse with options(
           &kGumboDefaultOptions, g page, g page len);
    char title [10240] = \{0\};
    parser title(output, title);
    printf("title = [%s]\n", title); //打印解析出的title
```

return 0;

# 整体程序,实现



### gumbo数据结构使用与算法

找到根节点(<html>标签)孩子中的<head>标签节点,再找到<head>标签孩子节点中的<title>标签节点,<title>标签节点中的第一个孩子即为最终需要提取的文本节点,提取该文本节点中的文本。

```
output->root->v.element
typedef struct GumboInternalOutput {
                                       typedef struct {
 GumboNode* document;
                                         void** data;
 GumboNode* root; //根节点
                                                                                                                html
                                         unsigned int length;
                                                                                   child->v.element.tag ==
 GumboVector errors;
                                         unsigned int capacity;
} GumboOutput;
                                        } GumboVector;
                                                                                   GUMBO TAG HEAD
typedef enum {
 GUMBO NODE DOCUMENT,
                                       typedef struct
                                         GumboVector children;
                                                                                                       child->v.element.tag ==
 GUMBO NODE ELEMENT, //标签节点
                                                                                                                                  body
                                                                                              head
                                         GumboTag tag;
 GUMBO NODE TEXT,
                                                                                                       GUMBO TAG TITLE
                                         GumboNamespaceEnum tag namespace;
 GUMBO NODE CDATA,
                                         GumboStringPiece original tag; ;
 GUMBO NODE COMMENT,
                                         GumboStringPiece original end tag
 GUMBO NODE WHITESPACE,
                                         GumboSourcePosition start pos;
 GUMBO NODE TEMPLATE
                                         GumboSourcePosition end pos;
GumboNodeType;
                                                                                               title
                                                                                                                         div
                                                                                                         #comment
                                                                                   meta
                                         GumboVector attributes;
                                       } GumboElement;
struct GumboInternalNode {
  GumboNodeType type;
                                                         //最终存储的文本
                                      typedef struct {
  GumboNode* parent;
                                                                                                        children[0]
                                         const char* text;
  size t index within parent;
  GumboParseFlags parse flags;
                                        GumboStringPiece original text;
                                                                             提取这个文本
                                                                                                                                             #text
                                                                                               #text
                                                                                                                                  a
  union {
                                        GumboSourcePosition start pos;
    GumboDocument document;
                                       } GumboText;
    GumboElement element;
                           //标签或文本
    GumboText text;
  } v;
                                                                                                                                #text
                                                                                                                    #tex
typedef struct GumboInternalNode GumboNode;
```

# 标题文本提取,课堂练习

```
void parser title(const GumboOutput *output, char title[]){
    const GumboVector *children = &(output->root->v.element.children);
    GumboNode* head = NULL;
   int i;
   for (i = 0; i
                                      i++) {
       GumboNode* child =
                                       2
       if (child->type == GUMBO NODE ELEMENT &&
                      3
                                  == GUMBO TAG_HEAD) {
            head = child;
            break:
    }
   children =
   for (i = 0; i
                                      i++) {
        GumboNode* child =
        if (child->type == GUMBO NODE ELEMENT &&
                                  == GUMBO TAG TITLE) {
            GumboNode *title text = child->v.element.children.data[0];
                strcpy(title, title text->v.text.text);
```

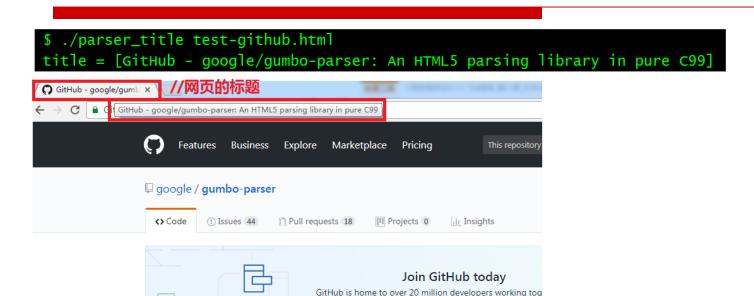
#### <mark>3分钟</mark>,填写代码 ,有问题提出!

```
typedef struct GumboInternalOutput {
 GumboNode* document;
 GumboNode* root; //根节点
 GumboVector errors;
} GumboOutput;
typedef enum {
  GUMBO NODE DOCUMENT,
 GUMBO NODE ELEMENT, //标签节点
  GUMBO NODE TEXT,
 GUMBO NODE CDATA,
 GUMBO NODE COMMENT,
 GUMBO NODE WHITESPACE,
  GUMBO NODE TEMPLATE
} GumboNodeType;
struct GumboInternalNode {
  GumboNodeType type;
  GumboNode* parent;
  size t index within parent;
  GumboParseFlags parse flags;
  union {
    GumboDocument document;
    GumboElement element;
                           //标签或文本
    GumboText text;
  } v;
typedef struct GumboInternalNode GumboNode;
typedef struct {
  void** data;
  unsigned int length;
  unsigned int capacity;
 } GumboVector;
                   //孩子数组
typedef struct
  GumboVector children;
  GumboTag tag;
  GumboNamespaceEnum tag namespace;
  GumboStringPiece original tag; ;
  GumboStringPiece original end tag,
  GumboSourcePosition start pos;
  GumboSourcePosition end pos;
  GumboVector attributes;
  GumboElement;
                  //最终存储的文本
typedef struct {
  const char* text
  GumboStringPiece original text;
  GumboSourcePosition start pos;
} GumboText;
```

# 标题文本提取,实现

```
void parser title(const GumboOutput *output, char title[]) {
                                                                           typedef struct GumboInternalOutput {
    const GumboVector *children = &(output->root->v.element.children);
                                                                             GumboNode* document;
                                                                            GumboNode* root; //根节点
    GumboNode* head = NULL;
                                                                            GumboVector errors;
   int i;
                                                                            GumboOutput;
                    children->length ; i++) {
   for (i = 0; i <
                                                                           typedef enum {
                                                                             GUMBO NODE DOCUMENT,
       GumboNode* child =
                                children->data[i];
                                                                            GUMBO NODE ELEMENT,
                                                                                                 //标签节点
       if (child->type == GUMBO NODE ELEMENT &&
                                                                             GUMBO NODE TEXT,
                                                                             GUMBO NODE CDATA,
             child->v.element.tag
                                  == GUMBO TAG HEAD) {
                                                                            GUMBO NODE COMMENT,
            head = child;
                                                                             GUMBO NODE WHITESPACE,
            break;
                                                                             GUMBO NODE TEMPLATE
                                                                            GumboNodeType;
                                                                           struct GumboInternalNode {
                 &(head->v.element.children);
   children =
                                                                             GumboNodeType type;
                                                                             GumboNode* parent;
                    children->length ; i++) {
                                                                             size t index within parent;
   for (i = 0; i
                                                                             GumboParseFlags parse flags;
        GumboNode* child =
                               children->data[i];
                                                                             union {
                                                                               GumboDocument document;
        if (child->type == GUMBO NODE ELEMENT &&
                                                                               GumboElement element;
                                                                                                       //标签或文本
                                                                               GumboText text;
             child->v.element.tag
                                  == GUMBO TAG TITLE) {
                                                                             v;
            GumboNode *title text = child->v.element.children.data[0];
                                                                           };
                                                                           typedef struct GumboInternalNode GumboNode;
                 title text->v.text.text
                strcpy(title, title text->v.text.text);
                                                                            typedef struct {
                                                                              void** data;
                                                                              unsigned int length;
                                                                              unsigned int capacity;
                                                                            } GumboVector;
                                                                                              //孩子数组
                                                        //最终存储的文本
                                     typedef struct
                                                                           typedef struct
                                                                             GumboVector children;
                                       const char* text;
                                                                             GumboTag tag;
                                       GumboStringPiece original text;
                                                                             GumboNamespaceEnum tag namespace;
                                       GumboSourcePosition start pos;
                                                                             GumboStringPiece original tag;
                                      GumboText;
                                                                             GumboStringPiece original end tag
                                                                             GumboSourcePosition start pos;
                                                                             GumboSourcePosition end pos;
                                                                             GumboVector attributes;
                                                                           } GumboElement;
```

### 编译与测试



and review code, manage projects, and build software

Sign up



#### Makefile

```
2 CC := gcc
3 INCLUDE := -I./output/include
4 LDFLAGS := -L./output/lib -lhtmlparser
5 CFLAGS := -Wall $(INCLUDE)
6
7 all: parser_title
8
9 parser_title: parser_title.c
10 $(CC) $(CFLAGS) -0 $@ $^ $(LDFLAGS)
11
12 clean:
13 rm parser_title
```

#### 课间休息10分钟!

# 有问题提出!



### 一些建议:关于学习

- 1. 掌握一门编译语言
- 2. 掌握算法与数据结构
- 3. 掌握一门脚本语言
- 4. 掌握开发环境
- 5. 丰富其他前沿知识



#### 一些建议:关于算法之路1

阶段0(初学乍练,不足挂齿): 学习了基础知识(如经典算法、数据结构等),一般为掌握知识或通过考试在纸上的练习写代码,好一点的主动编写一些小程序,全国50%以上的计算机专业的同学可能都在这阶段挣扎。

阶段1(粗懂皮毛,半生不熟): 基本的算法各类题型都已经见过,简单题或是难题加一起至少也刷过200多道,看到原题、熟题、模板题都可以解决,但是一到考察想法、或者很复杂的题目,单靠自己可能想不出来,需要看解题报告才可解决,反正照着他的思路写出来没问题。

阶段2(**已有小成,融会贯通**):一般难度的题目(leetcode 80%以上的题目应该都是一般难度的、ACM区域赛的部分题也是)都可以**独立解决**,虽然有的做的快点,有的做的慢点,但是这种题死磕一下肯定都通过,有了不错的举一反三能力。一般计算机专业的每个班都能有一两个同学达到这高度。

达到阶段2的时候,那么恭喜,只要再加上**系统性的训练**,什么BAT微软亚马逊的**算法面试**不 会难倒你的!:)



# 一些建议:关于算法之路2

阶段3(炉火纯青,出类拔萃): 刷leetcode这种非竞赛OJ早已经没感觉了,刷OJ也只刷中等偏上或者难题了,这样才能提高自己。这一阶段更重要的是培养临场竞赛能力, Topcoder SRM, odeforce,谷歌GCJ,百度之星之类的算法竞赛,有时间参加一定会玩一玩,状态好的时候打个前几名,状态差点反正差不到哪里去。Topcoder、Codeforce黄名或者红名的阶段。如果还有两个志同道合的好队友,ACM打个金奖也没什么问题。

阶段4(登峰造极,举世无双): Topcoder红色带靶心,世界上到这阶段的选手其实压指可数,ACM world final的奖牌是曾经的回忆,退役后有空也会玩一下,不小心就是某个比赛的第一名。题目早就不会再去刷了,无招胜有招。其实想到这阶段,光凭努力一般是不行的。最重要的还是天赋,就是天才那就是1%的灵感加上99%的汗水中的那1%的灵感。



#### 一些建议:关于面试

- 1. 听清并搞懂问题
- 2. 冷静思考
- 3. 努力解决,不轻易放弃
- 4. 自信并谦虚



#### 一些建议:关于实习

- 1. 实习是拿到BAT offer的捷径
- 2. 实习的岗位有许多:RD、QA、FE、OP、PM等
- 3. 尽量在一个实习岗位坚持半年
- 4. 实习还有不菲的薪水喔~
- 5. 关于学校课堂与上课, 自己把握



#### 一些建议:关于求职谈薪资

- 1.表达对工作、职位、技术的热爱: 在谈薪资时,不管满意与否,也不管是否手里还有其他offer,一定要对招聘方表达你对这个岗位工作的兴趣,因为站在招聘者的角度,只有有热情的候选人将来才能做好工作。
- 2.表达对期望薪资的客观理由:
- a.自身素质, 既然已经通过了各项技术面试, 那就说明已经胜任该工作岗位, 所以再表达一下也是应该的。
- b.竞品公司类似岗位,在谈薪资前,要对竞品公司的同职位的薪资有充分的了解,才能与更合理的与HR argue薪资。c.应聘公司的相应级别或岗位的一般待遇,因为同是职称(title),由于候选人个人素质不同,给的一般也不一样,要对该职称有整体了解。

#### 3.话不说死:

在这一阶段,无论HR如何施压(不马上签就没了),也不要马上答应或说死(不要马上对HR表达是否接受offer),要留有余地,这个潜台词是我可能还在看别的机会,但是对于这个岗位我仍然保有很大兴趣。

#### 4.接offer:

无论怎样,offer还是要接的,一般来讲,HR会给到他最终能给到的最高点(他也希望你入职,不然他本次的沟通就是无用的),但是不代表一定会入职,如果真不太满意,可以拿着这个offer再去找别家,骑着骡子找马嘛。反正入职时间可以往后拖一拖。

5.态度:积极、乐观、谦虚、自信:无论你们对该职位满意与否, 装也得装的这样。:)



#### 一些建议:关于职场

- 1. 正面看待工作中的各种问题,积极面对,让工作变得快乐
- 2. 遇到问题, 独立思考, 认真听取他人的建议, 自己做决定
- 3. 技术与产品的发展在于创新,<mark>敢于创新</mark>,即使创新可能带 来失败
- 4. 培养owner的精神, **勇于承担**,得到同事与上级的信任



#### 一些建议:大小公司的比较

大公司(优势):流程规范,最初成长快速,资源丰富,可以镀金增加将来的应聘 **竞争力**。建议校园招聘直接进入大公司。

大公司(劣势): **竞争激烈**,绩效严格,加班严重,等级比较严格。

小公司(优势):直接与公司管理者对话,工作灵活,一般竞争不会太激烈

,老板们也会较为珍惜人才

小公司(劣势):大公司优势的反面。



### 一些建议:关于人工智能

- 1. 人工智能时代的来临: PC桌面软件->互联网->移动互联网->人工智能
- 2. 人工智能的学习:打牢基础,接地气的解决问题,尝试新方法
- 3. 人工智能的就业:首选BAT等互联网行业巨头,不断<mark>积累</mark>,最终尝试创造新事物



### 广告: 算法与数据结构入门经典

# <mark>系统课</mark>)算法与数据结构 入门经典

双 老师: 林沐、林清

开课日期: 2018-06-23





#### 结束

# 非常感谢大家!

林沐



#### 问答互动

在所报课的课程页面,

- 1、点击"全部问题"显示本课程所有学员提问的问题。
- 2、点击"提问"即可向该课程的老师和助教提问问题。



#### 联系我们

小象学院: 互联网新技术在线教育领航者

- 微信公众号: 小象学院



